

Resolução do Problema Os Melhores Amigos (OMA) através da Meta-Heurística *Variable Neighborhood Search* (VNS)

Artur Bernardo de Souza Santos (00334726)

Lucca Claus (00334988)

21 de junho de 2026

1 Introdução

O presente trabalho aborda o problema denominado "Os Melhores Amigos"(OMA), classificado como um desafio de otimização combinatória em grafos. Dado um conjunto de n pessoas e valores de afinidade não negativa a_{ij} para cada par de indivíduos, o objetivo central consiste em selecionar um subconjunto exato de m pessoas que maximize a soma das afinidades mútuas entre os membros selecionados. Devido à sua natureza de explosão combinatória, a busca por uma solução exata torna-se computacionalmente intratável para instâncias de grande porte, justificando o desenvolvimento de métodos heurísticos. Este documento detalha a formulação matemática do problema, define e justifica as escolhas arquiteturais para a aplicação da meta-heurística *Variable Neighborhood Search* (VNS), e apresenta a análise dos resultados computacionais contrastando o desempenho da abordagem proposta com um solver exato.

2 Formulação Matemática

O problema OMA pode ser modelado como um programa inteiro linear. Para mitigar a não-linearidade gerada pelo produto de duas variáveis de decisão, introduz-se uma variável auxiliar para representar a escolha de um par, conforme detalhado a seguir.

Parâmetros:

n : O número total de pessoas disponíveis no conjunto P .

m : O tamanho exato exigido para o subconjunto de pessoas a ser selecionado.

a_{ij} : O valor numérico da afinidade (não negativa) entre a pessoa i e a pessoa j , para todo $1 \leq i < j \leq n$.

Variáveis de Decisão:

$x_i \in \{0, 1\}$: Assume valor 1 se a pessoa i for selecionada para o conjunto S , e 0 caso contrário, para todo $i \in \{1, \dots, n\}$.

$y_{i,j} \in \{0, 1\}$: Assume valor 1 se ambas as pessoas i e j forem selecionadas simultaneamente, e 0 caso contrário, para todo $1 \leq i < j \leq n$.

Função Objetivo:

O modelo visa maximizar a afinidade total do grupo formado:

$$\text{Maximizar } A(S) = \sum_{i=1}^{n-1} \sum_{j=i+1}^n a_{ij} y_{i,j} \quad (1)$$

Restrições:

$$\sum_{i=1}^n x_i = m \quad (2)$$

$$y_{i,j} \leq x_i \quad \forall 1 \leq i < j \leq n \quad (3)$$

$$y_{i,j} \leq x_j \quad \forall 1 \leq i < j \leq n \quad (4)$$

$$x_i \in \{0, 1\} \quad \forall i \in \{1, \dots, n\} \quad (5)$$

$$y_{i,j} \in \{0, 1\} \quad \forall 1 \leq i < j \leq n \quad (6)$$

A restrição (2) garante que o subconjunto selecionado contenha exatamente m pessoas, conforme exigido pelo problema. As restrições (3) e (4) estabelecem a relação entre as variáveis x_i , x_j e $y_{i,j}$, assegurando que a variável auxiliar $y_{i,j}$ só possa assumir valor 1 quando ambas as pessoas i e j forem selecionadas. Como a função objetivo busca maximizar a soma das afinidades e todos os coeficientes a_{ij} são não negativos, qualquer solução ótima tende a atribuir $y_{i,j} = 1$ sempre que $x_i = x_j = 1$. Dessa forma, a restrição clássica de limite inferior $y_{i,j} \geq x_i + x_j - 1$ torna-se desnecessária para este problema. Por fim, as restrições (5) e (6) definem o domínio binário das variáveis de decisão e das variáveis auxiliares.

3 Descrição e Justificativa da Abordagem Heurística

A estratégia selecionada para a resolução do OMA baseou-se na meta-heurística *Variable Neighborhood Search* (VNS). A opção por este método sustenta-se na sua capacidade sistemática de transitar entre diferentes estruturas de vizinhança para evitar convergências prematuras a ótimos locais, mantendo o custo computacional reduzido. Todas as escolhas de implementação focaram na eficiência assintótica da avaliação das soluções.

Representação do Problema e Estrutura de Dados: A solução é mantida por meio de uma estrutura híbrida: um vetor binário de tamanho n e uma lista estática de índices contendo os m elementos selecionados. *Justificativa:* O vetor binário assegura a consulta de pertinência em tempo $\mathcal{O}(1)$. Simultaneamente, a lista de índices restringe as iterações de laços ao subconjunto de tamanho m , evitando varreduras desnecessárias sobre o espaço n .

Geração da Solução Inicial: A configuração inicial é construída mediante uma heurística gulosa construtiva. O procedimento seleciona a aresta (par de vértices) de peso máximo no grafo da instância. A partir desta semente, o algoritmo incorpora iterativamente os indivíduos que apresentam o maior incremento marginal de afinidade com o subconjunto ativo, até a satisfação da restrição de cardinalidade m . *Justificativa:* Essa inicialização fornece um limite primal de alta qualidade, reduzindo substancialmente o esforço de convergência exigido na fase de Busca Local.

Avaliação da Função Objetivo (Cálculo do Delta): A avaliação de soluções vizinhas opera de forma estritamente diferencial. Em substituição ao cômputo da matriz completa — de complexidade $\mathcal{O}(m^2)$ —, determina-se a variação da afinidade (*Delta*) subtraindo as arestas incidentes ao vértice removido e somando as do vértice inserido. *Justificativa:* Este recálculo em tempo $\mathcal{O}(m)$ reduz a ordem de complexidade da rotina mais custosa do algoritmo, otimizando o tempo de processamento por iteração.

Estrutura de Vizinhança e Estratégia de Busca Local: A busca local emprega a vizinhança $\mathcal{N}_1$ (Swap 1-1), permutando um elemento de S por um elemento de $P \setminus S$. Utilizou-se o critério de transição *First Improvement*. *Justificativa:* O espaço de vizinhança possui dimensão $\mathcal{O}(m \times (n - m))$. Ao aliar o critério *First Improvement* ao cálculo de Δ em $\mathcal{O}(m)$, o algoritmo garante

uma convergência acelerada para o ótimo local estrito, mitigando o custo computacional exigido para uma exploração exaustiva inerente à adoção do critério *Best Improvement*.

Mecanismo de Perturbação (Shaking) e Parâmetros: Para diversificação no espaço de busca, o VNS adota vizinhanças de ordem superior $\mathcal{N}_k$ (Swap $k - k$). O algoritmo aplica uma perturbação estocástica ao permutar k elementos da solução atual. O valor de k inicia em 2 e avança a cada falha de melhoria global, limitado a um parâmetro de perturbação severa configurado em $k_{max} = \lceil m/2 \rceil$. *Justificativa:* Modificar dinamicamente até 50% da solução herdada proporciona uma agitação agressiva e profunda, essencial para garantir o escape assertivo de vales de ótimos locais de alta densidade sem perder as subestruturas construídas pela busca local.

Critérios de Terminação: O VNS encerra sua execução mediante o atingimento de um limite temporal (teto de 1500 segundos para equiparação aos testes exatos) ou pelo critério de estagnação, configurado rigorosamente para 1000 iterações consecutivas sem melhoria da função objetivo. *Justificativa:* A constatação de 1000 iterações de agitação severa malsucedidas atesta estatisticamente que a busca varreu intensivamente as bacias de atração e indica estabilidade da busca em ótimos locais de alta qualidade, justificando a interrupção. O fluxo da modelagem está sumarizado no Algoritmo 1.

Algoritmo 1 Meta-Heurística *Variable Neighborhood Search* (VNS)

Entrada: Grafo de afinidades P , tamanho do grupo m , tempo limite T_{max} , estagnação limite E_{max} , perturbação máxima k_{max} .
Saída: Melhor grupo S_{best} encontrado.
 $S \leftarrow \text{ConstrucaoGulosa}(P, m)$ ▷ Geração da solução inicial
 $S_{best} \leftarrow S$
 $k \leftarrow 2$
 $estagnacao \leftarrow 0$
enquanto $tempo_atual < T_{max}$ **e** $estagnacao < E_{max}$ **faça**
 $S' \leftarrow \text{Shaking}(S, k)$ ▷ Perturbação simultânea $k - k$
 $S'' \leftarrow \text{BuscaLocal}(S')$ ▷ First Improvement estrito na vizinhança $\mathcal{N}_1$
 se $A(S'') > A(S)$ **então**
 $S \leftarrow S''$
 $S_{best} \leftarrow S''$
 $k \leftarrow 2$ ▷ Reinicia estrutura de vizinhança em caso de melhora
 $estagnacao \leftarrow 0$
 senão
 $k \leftarrow k + 1$ ▷ Expande estrutura de vizinhança para maior perturbação
 se $k > k_{max}$ **então**
 $k \leftarrow 2$
 fim se
 $estagnacao \leftarrow estagnacao + 1$
 fim se
fim enquanto
retorne S_{best}

4 Avaliação Experimental e Resultados Computacionais

Os experimentos computacionais foram conduzidos nas instâncias oficiais do problema. Para atestar a estabilidade e a reprodutibilidade do método estocástico, os resultados do VNS denotam a média aritmética de 5 replicações independentes, submetidas a sementes pseudoaleatórias distintas.

4.1 Sintonia de Parâmetros

Para definir os parâmetros operacionais da meta-heurística e documentar rigorosamente a escolha da configuração final, conduziu-se uma etapa preliminar de calibração. O experimento consistiu na variação do gatilho de estagnação em quatro escalas (100, 300, 500 e 1000 iterações) e da intensidade da perturbação estocástica k_{max} em três limites proporcionais à cardinalidade do grupo: $\lceil m/8 \rceil$ (perturbação leve), $\lceil m/4 \rceil$ (perturbação moderada) e $\lceil m/2 \rceil$ (perturbação severa). A Tabela 1 expõe o valor da média global de qualidade alcançada sobre todas as instâncias e do respectivo tempo computacional dispendido para cada combinação paramétrica.

Tabela 1: Resultados da Calibração de Parâmetros do VNS

Configuração	Estagnação	Limite k_{max}	Qualidade Média	Tempo Médio (s)
1	100	$\lceil m/8 \rceil$ (leve)	583.68	0.007
2	100	$\lceil m/4 \rceil$ (moderada)	585.10	0.011
3	100	$\lceil m/2 \rceil$ (severa)	593.10	0.024
4	300	$\lceil m/8 \rceil$ (leve)	584.90	0.020
5	300	$\lceil m/4 \rceil$ (moderada)	586.64	0.030
6	300	$\lceil m/2 \rceil$ (severa)	594.00	0.067
7	500	$\lceil m/8 \rceil$ (leve)	585.60	0.034
8	500	$\lceil m/4 \rceil$ (moderada)	587.72	0.052
9	500	$\lceil m/2 \rceil$ (severa)	595.66	0.107
10	1000	$\lceil m/8 \rceil$ (leve)	585.98	0.068
11	1000	$\lceil m/4 \rceil$ (moderada)	589.64	0.109
12	1000	$\lceil m/2 \rceil$ (severa)	596.16	0.222

A análise experimental indica que a intensidade da perturbação exerce influência significativa no desempenho do VNS para as instâncias avaliadas. As diferentes configurações refletem a proporção do grupo de tamanho m que pode ser modificada durante a etapa de *Shaking*. Um limite de $\lceil m/8 \rceil$ permite substituir aproximadamente 12,5% dos integrantes do grupo, resultando em alterações relativamente pequenas na solução corrente. Embora essa estratégia preserve características promissoras da solução, os resultados sugerem que ela pode limitar a capacidade de exploração de regiões mais distantes do espaço de busca. De forma semelhante, a configuração intermediária $\lceil m/4 \rceil$ promove um nível moderado de diversificação ao permitir a troca de até 25% dos elementos selecionados. Já a configuração $\lceil m/2 \rceil$ produz perturbações mais intensas, possibilitando a substituição de até metade dos integrantes do grupo e favorecendo a exploração de soluções significativamente diferentes da atual.

Os resultados obtidos mostram que a **Configuração 12** apresentou o melhor desempenho médio entre todas as combinações avaliadas. A combinação entre perturbações mais intensas ($\lceil m/2 \rceil$) e um limite de estagnação de 1000 iterações permitiu ao algoritmo explorar o espaço de busca de forma mais ampla, alcançando uma qualidade média de 596.16. Esse valor foi calculado a partir da média dos resultados das 10 instâncias avaliadas, sendo que cada resultado individual corresponde à média de 5 execuções independentes com sementes pseudoaleatórias distintas. Embora essa configuração apresente um tempo de execução superior às demais, o tempo médio observado permaneceu reduzido ($\approx 0.222s$) quando comparado ao limite de 1500 segundos utilizado nos experimentos com o método exato. Em função desse desempenho, a Configuração 12 foi adotada como parâmetro padrão para as comparações apresentadas neste trabalho.

4.2 Desempenho da Meta-Heurística vs. Método Exato

Para propósitos de análise comparativa de performance e complexidade, o limite temporal estabelecido para a heurística VNS foi equalizado ao tempo de execução do modelo de Programação Linear Inteira via solver GLPK, fixando-se um teto máximo de 1500 segundos (25 minutos) para ambas as abordagens.

A Tabela 2 reporta os resultados obtidos pela meta-heurística VNS, evidenciando o Valor da Solução Inicial (SI), o Valor Final (SF), o desvio percentual de ganho intra-algoritmo (calculado matematicamente conforme as diretrizes do projeto pela fórmula $100 \times (SI - SF)/SI$) e o desvio percentual final em relação ao Melhor Valor Conhecido (BKV). Adicionalmente, a tabela apresenta os tempos de CPU despendidos pelo VNS contrastados diretamente com o tempo de execução do método exato.

Tabela 2: Resultados Computacionais - Meta-Heurística VNS (Configuração 1000-2) para o problema OMA

Instância	Val. Inicial (SI)	Valor Final (SF)	Desvio (SI) ¹	Desvio (Opt) ²	Tempo VNS (s)	Tempo Solver (s)
oma01.dat	433.00	471.80	-8.96%	0.04%	0.13	1511.65
oma02.dat	452.00	473.60	-4.78%	0.08%	0.12	1510.45
oma03.dat	446.00	464.00	-4.04%	1.28%	0.12	1516.07
oma04.dat	448.00	467.80	-4.42%	0.47%	0.13	1510.49
oma05.dat	459.00	472.20	-2.88%	0.38%	0.12	1509.82
oma06.dat	698.00	716.40	-2.64%	0.36%	0.26	1528.92
oma07.dat	693.00	724.00	-4.47%	0.00%	0.27	1527.06
oma08.dat	665.00	729.00	-9.62%	0.41%	0.46	1524.64
oma09.dat	677.00	733.00	-8.27%	0.00%	0.32	1528.20
oma10.dat	657.00	709.80	-8.04%	1.55%	0.30	1528.31

¹ Calculado com a seguinte equação: $100 \times (SI - SF)/SI$.

² Desvio percentual em relação aos Melhores Valores Conhecidos (BKV).

A meta-heurística VNS calibrada apresentou bom desempenho nas instâncias avaliadas, produzindo soluções de alta qualidade em tempos computacionais reduzidos. A solução inicial gulosa já fornece um ponto de partida competitivo, enquanto a combinação entre a busca local e o mecanismo de perturbação permite aprimorar progressivamente a afinidade total dos grupos gerados. Os resultados obtidos mostram desvios muito pequenos em relação aos melhores valores conhecidos (BKV), incluindo desvio nulo nas instâncias oma07 e oma09. Além disso, o tempo de execução permaneceu inferior a 0,46 segundos em todas as instâncias, valor significativamente menor que o limite de 1500 segundos adotado para comparação com o método exato. A Figura 1 ilustra a proximidade entre as soluções finais produzidas pelo VNS e os respectivos valores de referência (BKV).




Figura 1: Comparativo Visual de Afinidade: Solução Inicial vs. Solução Final VNS vs. BKV

Para elencar e constatar a extrema dificuldade de tratabilidade imposta pelo problema aos métodos exatos, a Tabela 3 descreve os resultados e os limites primais alcançados pela execução isolada do solver GLPK.

Tabela 3: Desempenho do Modelo Exato via Solver GLPK

Instância	n	m	Afinidade	Tempo (s)	Status
oma01.dat	125	12	346.00	1511.65	Limite de Tempo
oma02.dat	125	12	354.00	1510.45	Limite de Tempo
oma03.dat	125	12	337.00	1516.07	Limite de Tempo
oma04.dat	125	12	344.00	1510.49	Limite de Tempo
oma05.dat	125	12	366.00	1509.82	Limite de Tempo
oma06.dat	150	15	529.00	1528.92	Limite de Tempo
oma07.dat	150	15	519.00	1527.06	Limite de Tempo
oma08.dat	150	15	518.00	1524.64	Limite de Tempo
oma09.dat	150	15	488.00	1528.20	Limite de Tempo
oma10.dat	150	15	465.00	1528.31	Limite de Tempo

A análise da Tabela 3 evidencia as limitações práticas do modelo exato para as instâncias consideradas. Devido ao grande número de variáveis e restrições introduzidas pela linearização, o solver GLPK atingiu o limite de tempo de aproximadamente 25 minutos em todas as execuções. Em contrapartida, a meta-heurística VNS produziu soluções de alta qualidade em menos de um segundo. Por exemplo, para a instância oma01, o VNS obteve uma afinidade de 471.80, enquanto o valor reportado pelo GLPK ao final do limite temporal foi 346.00. Esses resultados indicam que, para as instâncias avaliadas, a abordagem heurística apresentou uma relação entre qualidade de solução e tempo computacional mais favorável.

5 Conclusão

A investigação experimental demonstrou a adequação da meta-heurística *Variable Neighborhood Search* para a resolução do problema "Os Melhores Amigos". Os resultados obtidos indicam

que a formulação de Programação Linear Inteira apresenta dificuldades computacionais para as instâncias avaliadas, exigindo tempos elevados de processamento sem alcançar soluções de qualidade comparável às produzidas pela abordagem heurística. Em contrapartida, o VNS, apoiado por uma solução inicial gulosa, busca local eficiente e mecanismo de perturbação progressiva, foi capaz de encontrar soluções de qualidade em tempos computacionais reduzidos.

A etapa de calibração permitiu identificar uma configuração de parâmetros adequada para o problema, destacando a importância de perturbações mais intensas na exploração do espaço de busca. Com essa configuração, a meta-heurística produziu soluções muito próximas dos melhores valores conhecidos, alcançando desvio nulo em algumas instâncias e mantendo um **gap** médio inferior a 0,5%. Além disso, todos os experimentos foram concluídos em menos de meio segundo por instância, evidenciando uma relação favorável entre qualidade de solução e tempo computacional.

Dessa forma, os resultados sugerem que o VNS constitui uma alternativa eficiente para a resolução das instâncias OMA consideradas neste trabalho, combinando boa qualidade de solução, baixo custo computacional e facilidade de implementação.

Referências

- [1] Ritt, Marcus. *Notas de aula da disciplina INF05010 - Otimização Combinatória*. Instituto de Informática, Universidade Federal do Rio Grande do Sul (UFRGS), 2026.
- [2] Souza, Marcone J. F.; Penna, Puca H. V. *Variable Neighborhood Search (VNS)*. Material Didático, Universidade Federal de Ouro Preto (UFOP). Disponível em: <http://www.decom.ufop.br/marcone/Disciplinas/InteligenciaComputacional/VNS.pdf>.